

Adversarial Emotion Manipulation against Audio Large Language Models

汇报人：徐振宇、李享

2026-03-19

1. Background
2. Motivation
3. Observation (Q1 – Q4)
4. Attack Design
5. 初步实验结果
6. 总结 & Q&A

音频 ≠ 纯文字转写；同时携带语义（说了什么）和副语言（韵律、情绪、身份）

ALLM 代表模型

SALMONN / Kimi-Audio / Voxtral-Mini-3B-2507

安全研究现状

文本 LLM	→ GCG [Zou et al., 2023]
视觉 MLLM	→ Mirage [Wang et al., 2024]
音频 ALLM	→ SpeechGuard [Peri et al., 2024]
情绪维度	→ 空白 ← 本研究

Motivation: 已有攻击都在做什么？

- C&W [Carlini & Wagner, 2018] — 攻击 ASR 转写内容
- SpeechGuard [Peri et al., 2024] — 越狱语音指令跟随模型
- WhisperInject [Kim et al., 2025] — 音频扰动越狱 ALLM
- AJailBench [Song et al., 2025] — ALLM 越狱基准
- Feng et al. [2025] — 观察情绪对 ALLM 安全性的影响（非攻击）

共同特点：攻击 ASR 语义 或 安全对齐，无人攻击情绪感知

Motivation: 为什么攻击情绪?

1. 下游决策直接依赖情绪

心理咨询、语音客服、情感陪伴 → 情绪误判导致不当回复策略

2. LLM 发展趋势：越来越关注人类情绪

- 具身智能、情感计算与 LLM 融合 [Zhang et al., 2024; Wang et al., 2024]
- LLM 拟人化方向（语音助手、陪伴机器人）→ 情绪感知成为核心能力
- 攻击面随能力扩展而扩大

3. 隐蔽性极强

扰动不可感知，语义不变，仅改变情绪感知 → 最难检测的攻击形式

Q1: 音频情绪存在翻转的可能性吗?

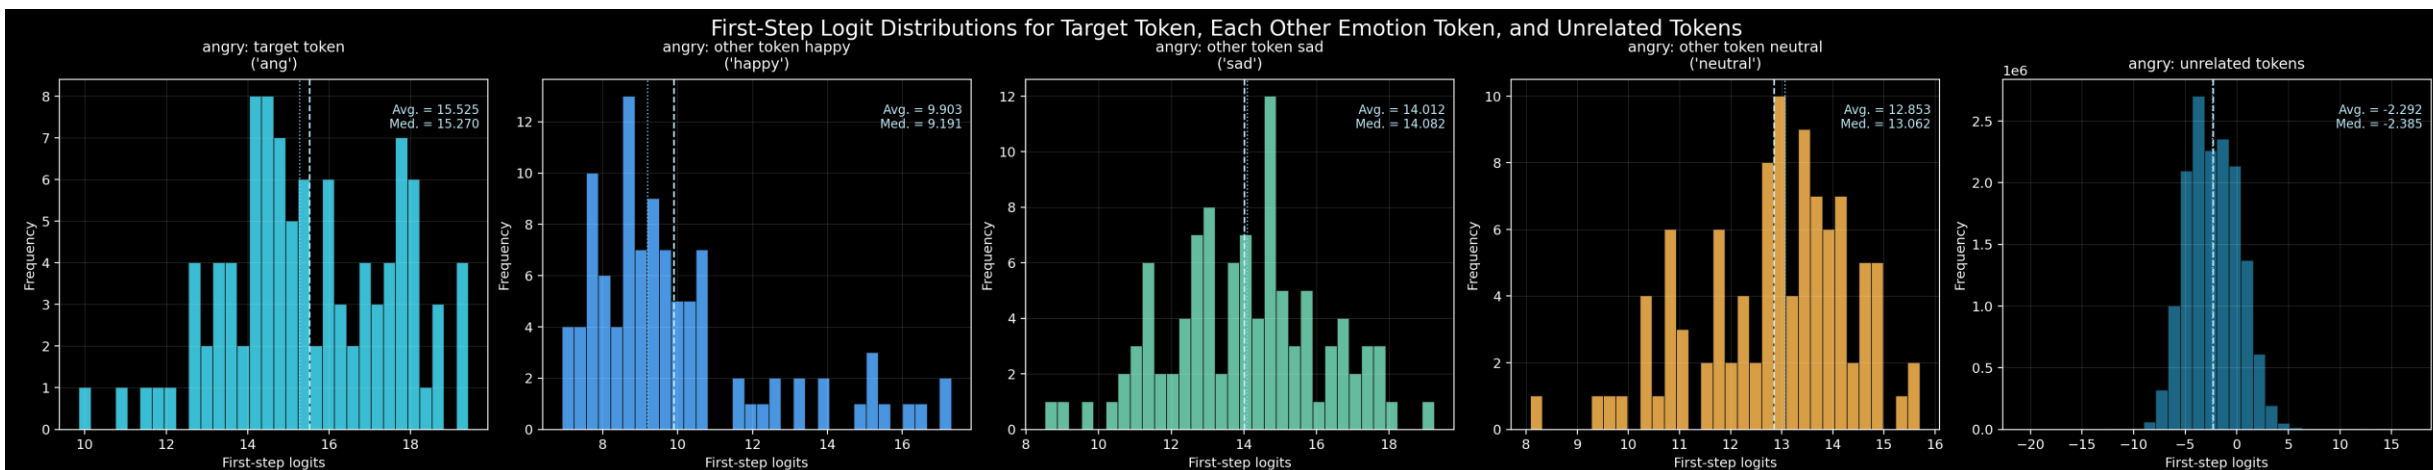

When Audio and Text Disagree: Benchmarking Text Bias in Large Audio-Language Models under Cross-Modal Inconsistencies (ACL 2025) 2025.12

之前的研究表面当语音情绪与文本信息产生冲突是文本主导

Qwen2-Audio-7B-Instruct, audio-only, 400 样本 (4 情绪 × 100)

询问模型语音的情绪具体是否什么?

得到的logit值分析发现当模型在分析情绪的过程中, 即使是情绪词非目标情绪的logit也可以有比无关键词高很多的输出倾向



Q2: 翻转了有什么后果?

Voxtral-Mini-3B, Aligned vs Conflict prompt, 15 样本, LLM (DeepSeek V3.2) Judge

维度 (指标)	Aligned	Conflict	Δ
Faithfulness	3.87	2.60	+1.27
Empathy	3.93	2.80	+1.13
Relevance	4.47	3.47	+1.00

关键发现

happy 最脆弱

Empathy Δ +3.00

sad 最鲁棒

$\Delta = 0$

neutral 幻觉温床

Faithfulness 1.33/5

核心结论

情绪误感知不只是标签翻转——它系统性地降低了回复的忠实度、共情恰当性与相关性，三维度平均下降 1.13 分。

Q3: 传统 SER 攻击方法对 ALLM 有效吗?

待执行实验

- SER 对抗样本方法（针对独立分类器）→ 迁移到 ALLM
- 预期翻转率低

原因

ALLM 情绪判断路径 $\neq$ 独立 SER 分类器


→ 引出 ALLM-specific 攻击设计

Q4: 情绪表征的内部结构?

Finding 1: 仲裁发生在晚期层 (26–28)

观察结果

通过对三组 (Audio-only / Conflict / Consistent) 做 Logit Lens 差分观察, 临界层基本发生在 26–28 层



Q4: 情绪表征的内部结构?

Finding 2: 文本因果主导，音频中层被wash-out



结论

Patch Text 在中层有效

文本指令在决策窗口（5–20）保持 强因果效应

Patch Audio 无效/不稳定

音频信号在中层被 structural wash-out




$$L(x') = \lambda_{emo} \cdot L_{emo} + \lambda_{asr} \cdot L_{asr} + \lambda_{per} \cdot L_{per}$$

损失项	作用	机制
L_emo	情绪翻转	Teacher-forcing CE on 情绪 token
L_asr	语义保持	转写 Prompt 下自一致约束
L_per	感知质量	多分辨率 STFT 幅度差

关键设计

- 两阶段调度：Stage A(20步)情绪优先
→ Stage B(40步)兼顾语义+可闻
- 多 Prompt 集成：3 个情绪 Prompt 求平均
- EoT 增强：随机时移 + 增益扰动
- 约束： $L_{\infty} \leq 0.008$

△ v1 方法论。

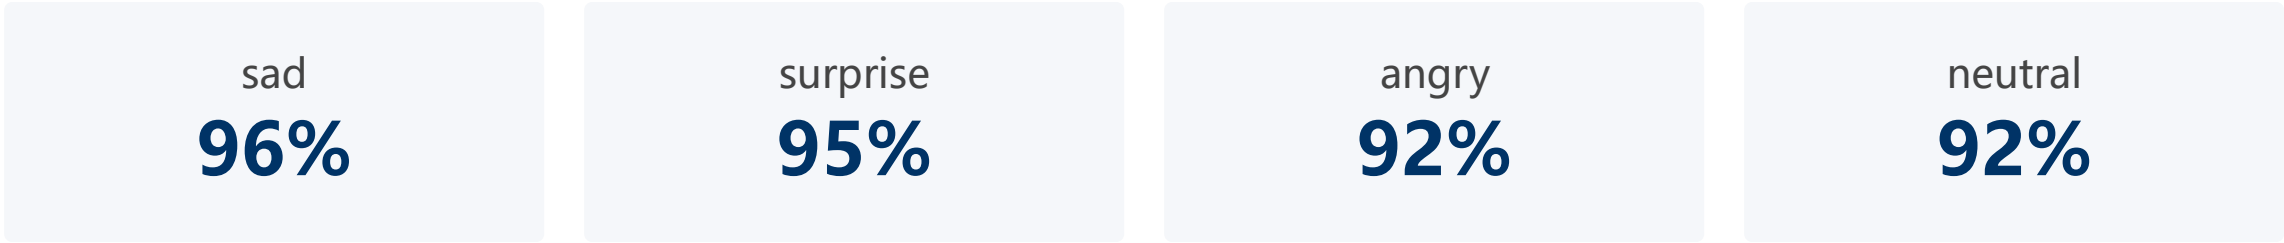


白盒实验：攻击成功率

结论先行：两个模型上情绪翻转均高度有效（78–94%），语义保持率差异大

模型	数据	样本量	ASR（多数投票）	单 Prompt 最高
Qwen	ESD	8949	78.44%	94.66%
Voxtral	ESD (EN+CN)	2000	93.80%	99.90%

Voxtral 按源情绪细分



指标	OpenS2S	Voxtral
语义保留率	19.43% (LLM Judge)	39.75% (Cosine Sim)
联合成功率	15.07%	36.40%
平均 SNR	16.43 dB	20.60 dB

关键发现

- 语义保持是联合成功率的限制因素
- Voxtral 优于 OpenS2S，可能与架构差异、模型质量有关

下一步

- Q3 实验：验证传统 SER 攻击迁移效果
- 方法论迭代：引入 Q4 启示 (soft distribution steering)

常规迁移

- 常规迁移的对抗样本可以对腾讯会议

元宝会议助手 刚刚

徐振宇 情绪高涨，连续表达了强烈的喜悦之情。从天气到心情都呈现出异常积极的状态，这种连贯的正面情绪流露较为罕见。

原音频

元宝会议助手 3分钟前

徐振宇 提到自己当前情绪不佳，可能暗示会议氛围紧张或存在未解决的矛盾。建议关注后续发言是否涉及具体冲突点。

对抗音频

在元宝会议助手测试50条生成的对抗样本测试，后续将输出给到Chatgpt 5.2外部判断情绪翻转成功率66%

- 常规迁移的对抗样本可以对chatgpt (3/30) 成功率10%

实时加噪

- 之前做过小样本训练的噪声，效果较差；通用性有待实现？
- 另外一种语音助手的固定命令的实验目前还在仿真

场景讨论

- 具身智能机器人：VLAS随时可以做
- 心理咨询：自己搭一个ai心理咨询的demo吗
- 智能眼镜的语音接口？

当前问题

- 缺少合适的商用模型（目前只有一个商用的智能客服API）
- 是否可以自己搭一个demo系统（如果是目标系统的话目的是服务偏差吗）可以考虑纯仿真吗

Thank You
