

Adversarial Emotion Manipulation against Audio Large Language Models

汇报人：徐振宇、李享

2026-03-19

1. Background
2. Motivation
3. Observation (Q1 – Q4)
4. Attack Design
5. 初步实验结果
6. 总结 & Q&A

音频 ≠ 纯文字转写；同时携带语义（说了什么）和副语言（韵律、情绪、身份）

ALLM 代表模型

SALMONN / Kimi-Audio / Voxtral-Mini-3B-2507

安全研究现状

文本 LLM	→ GCG [Zou et al., 2023]
视觉 MLLM	→ Mirage [Wang et al., 2024]
音频 ALLM	→ SpeechGuard [Peri et al., 2024]
情绪维度	→ 空白 ← 本研究

Motivation: 已有攻击都在做什么？

- C&W [Carlini & Wagner, 2018] — 攻击 ASR 转写内容
- SpeechGuard [Peri et al., 2024] — 越狱语音指令跟随模型
- WhisperInject [Kim et al., 2025] — 音频扰动越狱 ALLM
- AJailBench [Song et al., 2025] — ALLM 越狱基准
- Feng et al. [2025] — 观察情绪对 ALLM 安全性的影响（非攻击）

共同特点：攻击 ASR 语义 或 安全对齐，无人攻击情绪感知

Motivation: 为什么攻击情绪?

1. 下游决策直接依赖情绪

心理咨询、语音客服、情感陪伴 → 情绪误判导致不当回复策略

2. LLM 发展趋势：越来越关注人类情绪

- 具身智能、情感计算与 LLM 融合 [Zhang et al., 2024; Wang et al., 2024]
- LLM 拟人化方向（语音助手、陪伴机器人）→ 情绪感知成为核心能力
- 攻击面随能力扩展而扩大

3. 隐蔽性极强

扰动不可感知，语义不变，仅改变情绪感知 → 最难检测的攻击形式

Q1: 音频情绪可以翻转吗?

Qwen2-Audio-7B-Instruct, audio-only, 400 样本 (4 情绪 × 100)

情绪	候选集准确率	target gap < 0	主要 competitor
angry	61.0%	39.0%	sad (0.237)
sad	63.0%	37.0%	angry (0.309)
happy	15.0%	85.0%	angry (0.460)
neutral	24.0%	76.0%	angry (0.355)

happy 最弱

85% 样本目标分数
低于最强 competitor

angry 是万能 competitor

angry↔happy JS=0.0195
→ 翻转阻力最小

[FIG: Per-class Emotion-Token Probability Distribution (小提琴图)]

Q2: 翻转了有什么后果?

Voxtral-Mini-3B, Aligned vs Conflict prompt, 15 样本, LLM (DeepSeek V3.2) Judge

维度 (指标)	Aligned	Conflict	Δ
Faithfulness	3.87	2.60	+1.27
Empathy	3.93	2.80	+1.13
Relevance	4.47	3.47	+1.00

关键发现

happy 最脆弱

Empathy Δ +3.00

sad 最鲁棒

$\Delta = 0$

neutral 幻觉温床

Faithfulness 1.33/5

核心结论

情绪误感知不只是标签翻转——它系统性地降低了回复的忠实度、共情恰当性与相关性，三维度平均下降 1.13 分。

Q3: 传统 SER 攻击方法对 ALLM 有效吗?

待执行实验

- SER 对抗样本方法（针对独立分类器）→ 迁移到 ALLM
- 预期翻转率低

原因

ALLM 情绪判断路径 $\neq$ 独立 SER 分类器

→ 引出 ALLM-specific 攻击设计

Q4: 情绪表征的内部结构?

Prototype posterior: 每类情绪的平均后验分布

- happy 的 prototype 偏向 angry (angry 概率 0.460 > happy 自身 0.140)
- neutral 不以自身为中心 (angry 0.355 > neutral 0.251)
- sad 相对稳定, 但仍给 angry 留了不小质量

Prediction Confusion (行归一化)

→ 预测	angry	happy	sad	neutral
angry	0.610	0.070	0.230	0.090
happy	0.500	0.150	0.120	0.230
sad	0.300	0.020	0.630	0.050
neutral	0.360	0.050	0.350	0.240

- happy 最常被判为 angry
- neutral 在 angry/sad 间分裂

→ **anger-oriented
overlap region**

对攻击设计的启示

- 不宜只用 hard target CE → hybrid margin + soft distribution steering
- 需 pair-specific 策略 (尤其 happy→angry、neutral→angry)


$$L(x') = \lambda_{emo} \cdot L_{emo} + \lambda_{asr} \cdot L_{asr} + \lambda_{per} \cdot L_{per}$$

损失项	作用	机制
L_emo	情绪翻转	Teacher-forcing CE on 情绪 token
L_asr	语义保持	转写 Prompt 下自一致约束
L_per	感知质量	多分辨率 STFT 幅度差

关键设计

- 两阶段调度：Stage A(20步)情绪优先
→ Stage B(40步)兼顾语义+可闻
- 多 Prompt 集成：3 个情绪 Prompt 求平均
- EoT 增强：随机时移 + 增益扰动
- 约束： $L_{\infty} \leq 0.008$

△ v1 方法论。




白盒实验：攻击成功率

结论先行：两个模型上情绪翻转均高度有效（78–94%），语义保持率差异大

模型	数据	样本量	ASR（多数投票）	单 Prompt 最高
OpenS2S	ESD	8949	78.44%	94.66%
Voxtral	ESD (EN+CN)	2000	93.80%	99.90%

Voxtral 按源情绪细分



白盒实验：语义保持与扰动质量

指标	OpenS2S	Voxtral
语义保留率	19.43% (LLM Judge)	39.75% (Cosine Sim)
联合成功率	15.07%	36.40%
平均 SNR	16.43 dB	20.60 dB

关键发现

- 语义保持是联合成功率的限制因素
- Voxtral 优于 OpenS2S，可能与架构差异、模型质量有关

下一步

- Q3 实验：验证传统 SER 攻击迁移效果
- 方法论迭代：引入 Q4 启示 (soft distribution steering)
- 黑盒攻击探索

Thank You
