

Clean Emotion Token Analysis 总览

1. 这一部分在做什么

这部分的目标不是直接做攻击，而是先回答一个更基础的问题：

“Qwen2-Audio-7B-Instruct”在 clean audio-only 输入下，是如何“理解情绪”的？

更具体地说，我们固定同一个 audio-only prompt，只看四个候选情绪标签 `angry / happy / sad / neutral`，分析模型在输出位置对这些情绪标签的偏好分布，判断它更像：

- one-hot 式硬决策
- 还是带结构的 soft posterior preference

这一步的作用，是为后续 `audio-only emotion flip attack on SLMs` 设计更合理的 loss。

2. 实验设置

- 模型：`/data3/xuzhenyu/models/Qwen2-Audio-7B-Instruct`
- 数据：`/data3/xuzhenyu/OpenS2S/data/en\_query\_wav`
- 类别：`angry / happy / sad / neutral`
- 规模：pilot 共 `400` 条样本，每类 `100` 条
- 输入形式：严格 `audio-only`
- Prompt：

Identify the speaker's emotion from the audio. Reply with exactly one word: angry, happy, sad, or neutral.

- 观测位置：assistant 开始回答的第一个生成位置
- 主分析打分：`sequence\_log\_prob`

Tokenizer 说明：

- `happy`、`sad`、`neutral` 是单 token
- `angry` 在当前 chat template 下会拆成多 token
- 因此主实验统一使用 `sequence\_log\_prob` 聚合分数

3. 一页版结论

核心 observation

- `angry` 和 `sad` 在 clean 输入下有中等强度的目标占优，但都不是 one-hot
- `happy` 和 `neutral` 的 clean dominance 很弱，真实样本经常会被竞争情绪压过
- `angry` 是最主要的吸引盆地，`happy` 和 `neutral` 都明显朝 `angry` 区域塌
- prototype posterior 空间里，最接近的是 `angry` 和 `happy`
- 问题不是“全词表都很不确定”，而是“情绪子空间内部发生了系统性竞争和偏移”

对方法设计的含义

- 不适合只用 hard target CE
- 更适合 `hybrid margin + soft distribution steering`
- 尤其需要考虑涉及 `angry` 的 pair-specific / asymmetric objective

4. 主结果表

4.1 目标情绪是否稳定占优

真实情绪	候选集内准确率	目标概率均值	target-vs-second-best gap 均值	target gap < 0 的比例
---	---	---	---	---
angry	0.610	0.560	0.555	0.390
happy	0.150	0.140	-3.858	0.850
neutral	0.240	0.251	-2.097	0.760
sad	0.630	0.589	1.322	0.370

直接结论：

- `angry` 和 `sad` 有中等强度 dominance
- `happy` 和 `neutral` 不稳定
- `happy` 最弱，`85%` 的样本里目标分数低于最强 competitor

4.2 主要 competitor

真实情绪	主要 competitor	该 competitor 的均值概率
---	---	---
angry	sad	0.237
happy	angry	0.460
neutral	angry	0.355
sad	angry	0.309

4.3 Prototype posterior

真实情绪	q_angry	q_happy	q_sad	q_neutral
---	---	---	---	---
angry	0.560	0.077	0.237	0.125
happy	0.460	0.140	0.162	0.238
neutral	0.355	0.052	0.342	0.251
sad	0.309	0.022	0.589	0.079


Prototype 相似性要点：

- JS 最近：`angry` vs `happy`，`JS = 0.0195`
- 第二近：`angry` vs `neutral`
- JS 最远：`happy` vs `sad`

这说明 clean posterior 空间里存在一个很明显的 `anger-oriented overlap region`。

5. 图和解释

5.1 情绪 token 概率分布




这张图最直接地回答了“是不是 one-hot”：

- 不是
- `angry` 和 `sad` 虽然更集中，但仍保留明显 competitor mass
- `happy` 和 `neutral` 的目标分布更弱、更散

对应 observation：

- clean emotion understanding 更像 structured preference distribution
- 而不是纯 one-hot 分类


5.2 情绪 token logit 分布



这张图看的是候选情绪标签本身的分数分布。它和概率图一起说明：

- `angry`、`sad` 对应的目标标签整体更高
- `happy` 和 `neutral` 的分离度明显更弱
- 类间竞争不是偶发噪声，而是稳定结构

5.3 Target-vs-Others Gap




这张图对应“目标标签到底领先还是落后”。

读图重点：

- `sad` 和 `angry` 的 gap 更多落在正区间
- `happy` 和 `neutral` 经常落在负区间
- 尤其 `happy` 的目标标签经常打不过 competitor

5.4 Entropy 与 Confidence




这张图说明 posterior sharpness：

- 四类都不是 one-hot
- `sad` 最尖锐，但仍不是纯硬决策

- `happy`、`neutral` 更软，更像混叠 posterior

5.5 Prototype posterior




这张图适合看“每个真实情绪类的平均后验长什么样”。

最重要的点：

- `happy` 的 prototype 明显偏向 `angry`
- `neutral` 也并不以 `neutral` 为绝对中心
- `sad` 相对更稳，但仍给 `angry` 留了不小的质量

5.6 Prototype similarity




这张图说明不同真实情绪类在 prototype 空间里离得有多近。

读图重点：

- `angry` 和 `happy` 最接近
- `angry` 和 `neutral` 也比较近
- 不是所有 emotion pair 都同样容易区分

5.7 候选集内 confusion



按行归一化后的关键模式：

- `happy` 最常被判成 `angry`
- `neutral` 主要在 `angry` 和 `sad` 之间分裂
- `sad` 比 `happy`、`neutral` 稳，但仍有一部分会偏向 `angry`

这和前面的 prototype / probability 图是相互验证的。


6. 额外补充：目标 token / 其他情绪 token / 无关 token

这一部分是额外加的 first-step logit 分析，专门为了回答一个问题：

模型的问题到底是：

- 对整个词表都不确定
- 还是主要发生在“情绪子空间内部”？

6.1 三分版



这张图把 first-step logits 分成三类：


- 目标情绪 token
- 其他情绪 token
- 无关 token

注意：

- 这里的 `other emotion tokens` 是三种非目标情绪的 pooled distribution
- 不是把三者 logit 相加

- `angry` 在这张图里对应它的 first-step continuation token `ang`

6.2 细分版 4x5



这张图是你后来要求的细分版。每一行对应一个真实情绪，五列分别是：

- 目标情绪 token
- 其他情绪 1
- 其他情绪 2
- 其他情绪 3
- 无关 token

它回答得更清楚：

- `angry` 行：目标 `ang` 明显高，但 `sad` 也很高
- `happy` 行：目标 `happy` 明显低于 `angry`，也低于 `neutral`
- `sad` 行：目标 `sad` 最强，但 `angry` 也很高
- `neutral` 行：目标 `neutral` 不如 `angry` 和 `sad`

6.3 4x5 图的均值表

真实情绪	目标	其他 1	其他 2	其他 3	无关 token
angry	15.53 (`ang`)	9.90 (`happy`)	14.01 (`sad`)	12.85 (`neutral`)	-2.29
happy	11.20 (`happy`)	14.48 (`ang`)	12.80 (`sad`)	13.39 (`neutral`)	-2.51
sad	15.60 (`sad`)	14.10 (`ang`)	9.02 (`happy`)	11.99 (`neutral`)	-2.47
neutral	13.44 (`neutral`)	14.34 (`ang`)	10.04 (`happy`)	14.14 (`sad`)	-2.35

这个表最关键的 observation 是：

- 无关 token 始终在很低的负值区
- 问题不在“整个词表都混乱”
- 问题主要发生在情绪相关 token 之间
- `happy` 和 `neutral` 的 clean 语音已经被压进了一个更偏 `angry` 的竞争子空间

7. 这些图和我们最初预期是否一致

整体上是符合的，而且更强。

符合预期的部分：

- 我们原本预期 clean emotion understanding 不是纯 one-hot，而是结构化 posterior
- 现在 probability、entropy、prototype、similarity 图都支持这一点
- 这说明只用 hard CE 的设置偏弱

超出预期的部分：

- `happy` 和 `neutral` 不是“略微软一点”
- 而是在 clean 输入下就已经明显向 `angry` 区域偏移
- 尤其 `happy -> angry` 这个方向在 clean 状态下就很强

所以这轮结果比“soft but mostly correct”更强，已经接近：

`soft + asymmetric + anger-oriented overlap`

8. 对后续方法的启发

不建议

- 只做 hard target CE
- 把所有 emotion pair 当成等难度、等间距

更合理的方向

- `hybrid margin + soft distribution steering`
- `pair-specific prototype steering`
- 对涉及 `angry` 的方向做更强的非对称约束

一句话建议

如果后面要做 emotion flip attack，loss 最好同时考虑：

- 目标类的 margin
- 目标 prototype 的 soft alignment
- 以及 `happy -> angry`、`neutral -> angry` 这类 pair-specific 偏移

9. 文件索引

主文档

- `emotion\_token\_distribution\_summary.md`
- `clean\_emotion\_token\_analysis\_report.md`
- `clean\_emotion\_token\_analysis\_report\_zh.md`
- `first\_step\_target\_other\_unrelated\_logit\_histograms.md`
- `emotion\_token\_analysis\_reference\_zh.md`

图

- `figures/per\_class\_emotion\_token\_logit\_distribution.png`
- `figures/per\_class\_emotion\_token\_probability\_distribution.png`
- `figures/target\_vs\_others\_gap\_distribution.png`
- `figures/entropy\_confidence\_distribution.png`
- `figures/prototype\_posterior\_bar\_plot.png`
- `figures/interclass\_similarity\_matrix.png`
- `figures/prediction\_confusion\_matrix.png`
- `figures/first\_step\_target\_other\_unrelated\_logit\_histograms.png`
- `figures/first\_step\_target\_each\_other\_unrelated\_logit\_histograms.png`

表

- `tables/per\_class\_overview\_stats.csv`
- `tables/per\_class\_token\_logit\_stats.csv`
- `tables/per\_class\_token\_probability\_stats.csv`
- `tables/target\_vs\_competitor\_gap\_stats.csv`
- `tables/prediction\_confusion\_matrix\_counts.csv`
- `tables/prediction\_confusion\_matrix\_row\_normalized.csv`
- `tables/first\_step\_target\_other\_unrelated\_logit\_summary.csv`
- `tables/first\_step\_target\_each\_other\_unrelated\_logit\_summary.csv`